

Introduction à l'analyse computationnelle des textes (Université Saint Joseph, Beyrouth)

Marie BIZAIS

Mai-Juin 2026

1 Introduction

La formation proposée s'inscrit dans la maquette de licence du département de Lettres françaises (faculté des lettres et des sciences humaines) de l'Université Saint-Joseph de Beyrouth (Liban). Elle est conçue et dispensée par le consortium Huma-Num distam+, UAR 2999, CNRS, Paris.

Formatrices :

- Marie Bizais-Lillig (Université de Strasbourg, CNRS, Ecole nationale des chartes - PSL)
- Stéphanie Jabre Hage (Université Saint-Joseph)

La formation consiste en une initiation aux outils disponibles pour la recherche sur les textes (dans une perspectives essentiellement littéraire) assistée par ordinateur.

1.1 Calendrier :

1. Jeudi 21/05 de 17h à 19h : monter un projet numérique et rassembler ses données
2. Jeudi 28/05 de 17h à 19h : l'annotation en vue de l'extraction du texte
3. Jeudi 11/06 de 17h à 19h : la structuration du texte
4. Jeudi 25/06 de 17h à 19h : la fouille de texte (1/2)
5. Jeudi 02/07 de 17h à 19h : la fouille de texte (2/2)

2 Ressources

2.1 Ressources du cours

Le corpus ne sera pas stocké dans l'espace du cours en raison des droits de reproduction qui lui sont associés.

Toutefois, le parcours est reproductible sur la base des extraits fournis et des scripts mis à disposition.

Espace principal du cours : <https://github.com/Bizais-Lillig/cormatusj2026>

Des liens seront fournis aux étudiants de l'Université Saint-Joseph à titre privé dans une cadre pédagogique, ils permettront d'accéder à :

1. un fichier de travail (type pad)
2. les dossiers qui contiennent l'ensemble des données sur lesquelles nous travaillerons
3. un espace d'annotation (Label Studio, configuré par Chahan Vidal-Gorène, à l'Ecole nationale des chartes)

2.2 Autres ressources

Nous évoquerons au fil des semaines divers outils et documents, notamment :

(a) Le plan de gestion des données :

- Modèle ANR : https://anr.fr/fileadmin/documents/2019/ANR_DMP_Template_EN.pdf
- Outil de rédaction Opidor : <https://dmp.opidor.fr/>
- Un aperçu proposé par l'Université de l'Oregon : <https://guides.library.oregonstate.edu/dmp/general>
- Outil de rédaction DMPTool (MIT) : <https://libraries.mit.edu/data-management/plan/write/>

(b) La question des droits :

- Un survol des droits d'auteurs au Liban : https://www.irpi.fr/upload/pdf/etudes_juri/01_IRPI_Lanouvelle_loi_libanaise_sur_le_droit_d_auteur.pdf
- pour s'y retrouver facilement parmi les licences : <https://loantruong.github.io/choose-license/index.html>
- les licences Creative Commons : <https://creativecommons.org/cc-licenses/>
- la licence MIT : <https://loantruong.github.io/choose-license/licences/licence-mit.html>
- les licences Apache : <https://www.apache.org/licenses/LICENSE-2.0>

3 Semaine 1 : 21 mai 2026

Tour de table : Chacun se présente rapidement.

Introduction : Pourquoi s'appuyer sur l'informatique pour travailler sur du texte ? Nous évoquerons quelques exemples d'études, quelques perspectives et objectifs tout en soulignant les contraintes, points d'attentions, limites et conditions de ce type de travail. Nous replacerons la réflexion dans l'histoire des humanités numériques et de la philologie computationnelle dans une perspective de transformation constante.

Cadrage scientifique : On commence par envisager un projet de recherche, on définit une problématique et on s'interroge sur ses conditions de mise en oeuvre, à savoir la délimitation du corpus et son "acquisition", la méthodologie et le cadre épistémique, les besoins en termes de compétences et de méthode ou outil. En cas d'outillage numérique, on s'interrogera sur les conditions d'utilisation de notre corpus, sur les outils et formats à privilégier, sur les "livrables" et la manière dont on veut les partager/publier.

Le plan de gestion de données (PGD) : Un outil pour préparer un projet, réfléchir à ces questions-clés, qui s'avérera très utile en cas de travail en équipe. Nous examinerons un exemple de PGD (DMP, *data management plan* en anglais) minimaliste pour en comprendre les principes et discuter des licences (avec un focus sur les licence Creative Commons et les licences MIT et Apache).

Charles Corm : Après une explication sur le choix de l'oeuvre de Charles Corm (en lien notamment avec la question des droits d'auteurs au Liban et le choix linguistique du français en lien avec le contexte d'enseignement et les compétences de l'enseignante), nous discuterons des caractéristiques de son oeuvre et des représentations qui y sont associées.

L'acquisition des données : Deux modalités se sont imposées après la consultation des catalogues de bibliothèques, des bibliothèques en ligne et de Wikisource, en tenant compte des licences associées aux textes consultables en ligne.

Scraper le web : Nous parcourrons un court notebook en Python utilisé pour récupérer les images du premier livre sur lequel nous travaillerons.

Identifier la nature des données dont nous disposons : Nous comparerons nos deux ressources, d'une part des images d'un livre au format JPEG, de l'autre un livre au format PDF qui n'est pas une image mais du texte.

Extraire le texte : Nous montrerons comment récupérer le texte du PDF et expliquerons pourquoi nous souhaitons le récupérer au format TXT. Nous reviendrons sur le résultat obtenu à l'occasion de la troisième séance. Nous nous concentrerons pour finir sur les tâches de traitement qu'exigent les images.

L'OCR : Elle nécessite deux étapes. La première étape est celle de l'identification des zones de texte. Pour cela, nous allons utiliser un modèle YOLO pour une tâche de détection sous la forme de *bounding boxes*. Nous allons voir ce que produit le modèle sans informations de départ quant au résultat obtenu. Nous allons ensuite décider quel résultat nous voulons obtenir. Un travail d'annotation s'ensuivra (cf. le paragraphe suivant) qui permettra un entraînement du modèle qui sera présenté le 28 mai. La segmentation ainsi obtenue permettra de récupérer les lignes de textes "inscrites" sur les images du livre.

Travail pour le 27 mai 12h : Chacun des étudiants annotera 7 images du corpus selon une répartition qui sera indiquée en fin de séance le 21 mai.

4 Semaine 2 : 28 mai 2026